

v

Índice general

Resumen	1
1. Introducción general	1
1.1. Contexto del trabajo	1
1.2. Estado del arte	2
1.3. Motivación	3
1.4. Objetivos y alcance	3
2. Introducción específica	7
2.1. Técnicas de procesamiento de datos	7
2.1.1. Detección y tratamiento de outliers	7
2.1.2. Escalado de variables	8
2.1.3. Balanceo de dataset	9
2.1.4. Selección de features	9
2.2. Modelos de inteligencia artificial	9
2.3. Optimización de hiperparámetros	10
2.4. Herramientas - Tracking server	10
2.5. Herramientas para automatización	10
2.6. Desarrollo de API y herramientas para su consumo	11
2.7. Uso de contenedores	11
3. Diseño e implementación	13
3.1. Flujo de trabajo	13
3.1.1. Etapas del flujo de trabajo	13
3.1.2. Implementación del flujo de trabajo	14
3.2. Arquitectura del sistema	14
3.2.1. Arquitectura del ambiente local	14
3.2.2. Arquitectura del ambiente dockerizado	15
3.3. Preprocesamiento de datos	16
3.3.1. División del dataset	16
3.3.2. Tratamiento de nulos y outliers	17
3.3.3. Escalado de datos	18
3.3.4. Balanceo del dataset	20
3.3.5. Selección de features	20
3.4. Optimización y entrenamiento de modelos	21
3.4.1. Pipelines y modelos	21
3.4.2. Cross validation e implementación durante optimización	22
3.4.3. Modelo Logistic Regression	22
3.4.4. Modelo SVM	23
3.4.5. Modelo XGBoost	24
3.4.6. Selección del mejor modelo	26
3.5. Tracking server	26

v

Índice general

Resumen	1
1. Introducción general	1
1.1. Contexto del trabajo	1
1.2. Estado del arte	2
1.3. Motivación	3
1.4. Objetivos y alcance	4
2. Introducción específica	7
2.1. Técnicas de procesamiento de datos	7
2.1.1. Detección y tratamiento de outliers	7
2.1.2. Escalado de variables	8
2.1.3. Balanceo de dataset	9
2.1.4. Selección de features	9
2.2. Modelos de inteligencia artificial	9
2.3. Optimización de hiperparámetros	10
2.4. Herramientas - Tracking server	10
2.5. Herramientas para automatización	10
2.6. Desarrollo de API y herramientas para su consumo	11
2.7. Uso de contenedores	11
3. Diseño e implementación	13
3.1. Flujo de trabajo	13
3.1.1. Etapas del flujo de trabajo	13
3.1.2. Implementación del flujo de trabajo	14
3.2. Arquitectura del sistema	14
3.2.1. Arquitectura del ambiente local	14
3.2.2. Arquitectura del ambiente dockerizado	15
3.3. Preprocesamiento de datos	16
3.3.1. División del dataset	16
3.3.2. Tratamiento de nulos y outliers	17
3.3.3. Escalado de datos	18
3.3.4. Balanceo del dataset	20
3.3.5. Selección de features	20
3.4. Optimización y entrenamiento de modelos	21
3.4.1. Pipelines y modelos	21
3.4.2. Cross validation e implementación durante optimización	22
3.4.3. Modelo Logistic Regression	22
3.4.4. Modelo SVM	23
3.4.5. Modelo XGBoost	24
3.4.6. Selección del mejor modelo	26
3.5. Tracking server	26

Índice de tablas

2.1. Técnicas utilizadas 7

3.1. Técnicas utilizadas 20

3.2. Hiperparámetros - LR 23

3.3. Hiperparámetros - SVM 24

3.4. Hiperparámetros - XGBoost 25

4.1. Métricas de modelos. 31

4.2. Resultados de métricas de modelos. 32

4.3. Comparación mediante recall 35

4.4. Evaluación del dataset de Polonia 40

4.5. Evaluación del dataset ruso 42

4.6. Evaluación del dataset estadounidense 43

Índice de tablas

1.1. Ratios financieros de z-score 2

2.1. Técnicas utilizadas 7

3.1. Técnicas utilizadas 20

3.2. Hiperparámetros - LR 23

3.3. Hiperparámetros - SVM 24

3.4. Hiperparámetros - XGBoost 25

4.1. Métricas de modelos. 31

4.2. Resultados de métricas de modelos. 32

4.3. Comparación mediante recall 35

4.4. Evaluación del dataset de Polonia 40

4.5. Evaluación del dataset ruso 42

4.6. Evaluación del dataset estadounidense 43

de una región y el Producto Bruto Internto (PBI), dependiendo del tamaño e influencia de la empresa afectada.

- Socialmente, el desempleo es la consecuencia más directa de una quiebra. Dependiendo de la cantidad de gente afectada, se podría incluso hablar de una recesión a nivel local.
- Legalmente, los procedimientos pueden durar meses o años, y esto consume recursos que se podrían haber utilizado para pagar deudas. También puede presentar ciertos conflictos de interés entre los acreedores y otros interesados, por ejemplo, al definir quién tiene prioridad sobre el cobro de sus obligaciones.

Es por esto que la predicción de quiebra de una empresa resulta fundamental para distintos interesados. Inversionistas y accionistas podrían decidir si comprar o vender acciones ante una posible pérdida de valor; entidades bancarias evaluarían la calidad crediticia de una empresa y tendrían mejor información para determinar si les otorgan un préstamo o no; algunos proveedores podrían ajustar condiciones de crédito y evitar impagos; los gobiernos podrían diseñar políticas de rescate y apoyo; e incluso la propia gerencia de una empresa podría utilizarla como un sistema de alerta temprana, a fin de implementar medidas de reestructuración o de reducción de costos a fin de evitar la quiebra.

1.2. Estado del arte

Existen diversos estudios, técnicas, mecanismos e incluso soluciones de software que permiten predecir la quiebra de empresas.

Hay estudios que buscan encontrar soluciones generales a esta problemática. Por ejemplo, la fórmula matemática *z-score* de Altman [2] utiliza cinco ratios **financieros** para obtener la probabilidad de que una empresa quiebre en los próximos dos años. Otras soluciones más modernas, como la propuesta en el paper *Bankruptcy Prediction Using Machine Learning and Data Preprocessing Techniques* [3], proponen el uso de modelos de *machine learning* y técnicas de **preprocesamiento** de datos para solucionar este problema.

Otros estudios se basan en el análisis de un dataset en particular. Por ejemplo, para el dataset de *Taiwanese Bankruptcy Prediction* [4] hay estudios como *Comprehensive Evaluation of Bankruptcy Prediction in Taiwanese Firms Using Multiple Machine Learning Models*, en donde se exploran distintos modelos de *machine learning*; mientras que en otros, como en *Undersampling bankruptcy prediction: Taiwan bankruptcy data* [5], se estudian los resultados de aplicar ciertas técnicas de preprocesamiento sobre el dataset, más precisamente, técnicas de *undersampling*.

En cuanto a soluciones de software, existen herramientas como Gini Machine [6], una plataforma de análisis predictivo basada en aprendizaje automático, y diseñada bajo el enfoque *no-code*.

Si bien el estado del arte para la predicción de quiebra de empresas presenta diferentes soluciones, se observan ciertas desventajas en la mayoría de ellas.

Por ejemplo, en el caso de los estudios y papers, estos son útiles porque describen qué métodos, qué técnicas de procesamiento y qué modelos les permitieron

de una región y el Producto Bruto Internto (PBI), dependiendo del tamaño e influencia de la empresa afectada.

- Socialmente, el desempleo es la consecuencia más directa de una quiebra. Dependiendo de la cantidad de gente afectada, se podría incluso hablar de una recesión a nivel local.
- Legalmente, los procedimientos pueden durar meses o años, y esto consume recursos que se podrían haber utilizado para pagar deudas. También puede presentar ciertos conflictos de interés entre los acreedores y otros interesados, por ejemplo, al definir quién tiene prioridad sobre el cobro de sus obligaciones.

Es por esto que la predicción de quiebra de una empresa resulta fundamental para distintos interesados. Inversionistas y accionistas podrían decidir si comprar o vender acciones ante una posible pérdida de valor; entidades bancarias evaluarían la calidad crediticia de una empresa y tendrían mejor información para determinar si les otorgan un préstamo o no; algunos proveedores podrían ajustar condiciones de crédito y evitar impagos; los gobiernos podrían diseñar políticas de rescate y apoyo; e incluso la propia gerencia de una empresa podría utilizarla como un sistema de alerta temprana, a fin de implementar medidas de reestructuración o de reducción de costos a fin de evitar la quiebra.

1.2. Estado del arte

Existen diversos estudios, técnicas, mecanismos e incluso soluciones de software que permiten predecir la quiebra de empresas.

Hay estudios que buscan encontrar soluciones generales a esta problemática. Por ejemplo, la fórmula matemática *z-score* de Altman [2] utiliza cinco ratios **financieros** (ver tabla 1.1) para obtener la probabilidad de que una empresa quiebre en los próximos dos años. Otras soluciones más modernas, como la propuesta en el paper *Bankruptcy Prediction Using Machine Learning and Data Preprocessing Techniques* [3], proponen el uso de modelos de *machine learning* y técnicas de **preprocesamiento** de datos para solucionar este problema.

TABLA 1.1. Ratios financieros de *z-score*.

Ratio	Descripción
X_1 (Capital de Trabajo / Activos Totales)	Liquidez neta en relación con el tamaño de la firma.
X_2 (Utilidades Retenidas / Activos Totales)	Refleja la rentabilidad acumulada y la edad de la empresa.
X_3 (EBIT / Activos Totales)	Mide la eficiencia operativa real de los activos, independientemente de impuestos o apalancamiento.
X_4 (Valor de Mercado del Patrimonio / Deuda Total)	Evalúa la solvencia añadiendo una dimensión de mercado (precio de la acción).
X_5 (Ventas / Activos Totales)	Muestra la capacidad de los activos para generar ingresos.

realizar predicciones y obtener buenos resultados. Sin embargo, ninguno de estos trabajos expone sus modelos mediante una herramienta de acceso público. Reproducir los resultados exige no solo dominio técnico en áreas como ciencia de datos o *machine learning*, sino también la recolección y preparación de datos propios. Esto resulta prohibitivo para todos aquellos usuarios no especializados que podrían beneficiarse de estas herramientas.

Por su parte, Gini Machine resuelve algunas de las problemáticas mencionadas, ya que es una solución *no-code*, es decir, es de uso fácil para aquellos usuarios sin conocimientos programación, de estadística y de *machine learning*. Sin embargo, esta herramienta presenta ciertas desventajas, tales como un alto costo de uso, requerir que el usuario entienda qué datos son importantes para armar un buen dataset, e incluso requiere que la cantidad de datos presentados para armar un modelo sean como mínimo 1000 registros [7].

1.3. Motivación

Tal como se expresó en las secciones anteriores, la predicción de quiebra de una empresa representa información de gran valor para distintos actores del mercado financiero. Contar con esta información de manera oportuna les permitirá a bancos, aseguradoras, fondos de inversión y otros actores del sistema financiero tomar decisiones informadas frente a la inminente quiebra de una compañía bajo análisis.

Si bien hoy existen diferentes soluciones a estas problemáticas, que abarcan desde papers hasta soluciones de software, ninguna de estas ofrece una solución de uso fácil para cualquier tipo de usuario, especialmente para aquellos que no poseen conocimientos técnicos en áreas de matemática, estadística, *machine learning* o incluso programación.

Esto constituye la motivación principal de este trabajo: la creación y la puesta en marcha de un sistema que permita predecir si una empresa entra en quiebra, priorizando que este sea de fácil acceso y uso para usuarios poco experimentados.

1.4. Objetivos y alcance

El objetivo de este trabajo consiste en satisfacer las necesidades de distintos actores del mercado financiero respecto a la predicción de quiebra de una empresa. Para ello, se diseña, se crea y se expone un sistema que permita realizar este tipo de predicciones. Este sistema se publica mediante un servicio web, de modo que sea de fácil acceso para los interesados. Respecto al diseño, el sistema requiere únicamente el ingreso de los datos de una empresa de su interés. De esta forma se eliminan las desventajas presentes en soluciones actuales, tales como el ingreso de gran cantidad de datos para realizar predicciones, como así también tener conocimiento a nivel técnico de los datos presentados.

Para lograr este objetivo, se definió el siguiente alcance:

- Identificar el set de datos para el problema: en este caso, se utiliza el dataset de origen público *Taiwanese Bankruptcy Prediction* [4].

Otros estudios se basan en el análisis de un dataset en particular. Por ejemplo, para el dataset de *Taiwanese Bankruptcy Prediction* [4] hay estudios como *Comprehensive Evaluation of Bankruptcy Prediction in Taiwanese Firms Using Multiple Machine Learning Models*, en que se exploran distintos modelos de *machine learning*; mientras que en otros, como en *Undersampling bankruptcy prediction: Taiwan bankruptcy data* [5], se estudian los resultados de aplicar ciertas técnicas de preprocesamiento sobre el dataset, más precisamente, técnicas de *undersampling*.

En cuanto a soluciones de software, existen herramientas como Gini Machine [6], una plataforma de análisis predictivo basada en aprendizaje automático, y diseñada bajo el enfoque *no-code*.

Si bien el estado del arte para la predicción de quiebra de empresas presenta diferentes soluciones, se observan ciertas desventajas en la mayoría de ellas.

Por ejemplo, en el caso de los estudios y papers, estos son útiles porque describen qué métodos, qué técnicas de procesamiento y qué modelos les permitieron realizar predicciones y obtener buenos resultados. Sin embargo, ninguno de estos trabajos expone sus modelos mediante una herramienta de acceso público. Reproducir los resultados exige no solo dominio técnico en áreas como ciencia de datos o *machine learning*, sino también la recolección y preparación de datos propios. Esto resulta prohibitivo para todos aquellos usuarios no especializados que podrían beneficiarse de estas herramientas.

Por su parte, Gini Machine resuelve algunas de las problemáticas mencionadas, ya que es una solución *no-code*, es decir, es de uso fácil para aquellos usuarios sin conocimientos programación, de estadística y de *machine learning*. Sin embargo, esta herramienta presenta ciertas desventajas, tales como un alto costo de uso, requerir que el usuario entienda qué datos son importantes para armar un buen dataset, e incluso requiere que la cantidad de datos presentados para armar un modelo sean como mínimo 1000 registros [7].

1.3. Motivación

Tal como se expresó en las secciones anteriores, la predicción de quiebra de una empresa representa información de gran valor para distintos actores del mercado financiero. Contar con esta información de manera oportuna les permitirá a bancos, aseguradoras, fondos de inversión y otros actores del sistema financiero tomar decisiones informadas frente a la inminente quiebra de una compañía bajo análisis.

Si bien hoy existen diferentes soluciones a estas problemáticas, que abarcan desde papers hasta soluciones de software, ninguna de estas ofrece una solución de uso fácil para cualquier tipo de usuario, especialmente para aquellos que no poseen conocimientos técnicos en áreas de matemática, estadística, *machine learning* o incluso programación.

Esto constituye la motivación principal de este trabajo: la creación y la puesta en marcha de un sistema que permita predecir si una empresa entra en quiebra, priorizando que este sea de fácil acceso y uso para usuarios poco experimentados.

- Conducir un análisis exploratorio de datos: estudiar el dataset en cuestión es de vital importancia para conocer sus características, distribuciones, y potenciales errores a corregir.
- Realizar un preprocesamiento de datos: aplicar distintas técnicas de eliminación de duplicados, corrección de datos faltantes, corrección de *outliers*, balanceo de datos, selección de *features* más importantes, entre otras, que son de suma importancia para mejorar la calidad del dataset.
- Implementar modelos de *machine learning*: es necesario implementar técnicas robustas, tales como SVM [8], logistic regression [9] y XGBoost [10], que permitan realizar tareas de clasificación. De esta manera, se presentan resultados de calidad al usuario.
- Optimizar hiperparámetros de modelos de *machine learning*: es fundamental refinar detalles relacionados a la configuración de los modelos empleados, a fin que la calidad de los resultados sean superiores.
- Obtener métricas y gráficos de cada modelo: estos les otorgan información extra a los usuarios respecto al contexto de sus predicciones.
- Comparar modelos y seleccionar el óptimo: es fundamental que el sistema le permita al usuario final realizar predicciones mediante el mejor modelo posible. Por ello, se comparan los distintos modelos entrenados y optimizados, a fin de encontrar al mejor de ellos.
- Seguimiento de resultados: al entrenar y comparar distintos modelos, es necesario hacer un seguimiento y una persistencia de ellos, como así también de sus métricas y gráficos. Esto facilita la consulta de esta información en distintas etapas, como así también su disposición para las consultas de los usuarios.
- Automatizar etapas: es de suma importancia que las etapas de análisis, optimización, entrenamiento y seguimiento de modelos sean automatizadas. Esto agiliza el ciclo de vida de la aplicación, permitiendo que las mejoras aplicadas al sistema sean publicadas de forma rápida y sencilla para el consumo de los usuarios.
- Crear un servicio web: mediante una API web, un usuario puede realizar predicciones de quiebra al proveer los datos de una empresa en particular. También puede consultar métricas y gráficas de los modelos involucrados, incluyendo al mejor de ellos.

Por otra parte, dentro de las actividades que quedaron excluidas del alcance, se pueden mencionar:

- Despliegue online: el trabajo realizado se expone como un servicio web que se puede ejecutar de manera local. Es decir, no fue desplegado en plataformas de *cloud computing*, tales como Azure [11], AWS [12], Google Cloud [13], entre otras.
- Creación de interfaz web: el trabajo abarca desde la definición de un dataset, hasta la publicación de un servicio web que permite realizar predicciones de quiebra de una empresa. No se desarrolló un sitio web para consumir este servicio. No obstante, el servicio podrá ser utilizado mediante otras herramientas existentes, tales como cURL [14].

1.4. Objetivos y alcance

El objetivo de este trabajo consiste en satisfacer las necesidades de distintos actores del mercado financiero respecto a la predicción de quiebra de una empresa. Para ello, se diseña, se crea y se expone un sistema que permita realizar este tipo de predicciones. Este sistema se publica mediante un servicio web, de modo que sea de fácil acceso para los interesados. Respecto al diseño, el sistema requiere únicamente el ingreso de los datos de una empresa de su interés. De esta forma se eliminan las desventajas presentes en soluciones actuales, tales como el ingreso de gran cantidad de datos para realizar predicciones, como así también tener conocimiento a nivel técnico de los datos presentados.

Para lograr este objetivo, se definió el siguiente alcance:

- Identificar el set de datos para el problema: en este caso, se utiliza el dataset de origen público *Taiwanese Bankruptcy Prediction* [4].
- Conducir un análisis exploratorio de datos: estudiar el dataset en cuestión es de vital importancia para conocer sus características, distribuciones, y potenciales errores a corregir.
- Realizar un preprocesamiento de datos: aplicar distintas técnicas de eliminación de duplicados, corrección de datos faltantes, corrección de *outliers*, balanceo de datos, selección de *features* más importantes, entre otras, que son de suma importancia para mejorar la calidad del dataset.
- Implementar modelos de *machine learning*: es necesario implementar técnicas robustas, tales como SVM [8], logistic regression [9] y XGBoost [10], que permitan realizar tareas de clasificación. De esta manera, se presentan resultados de calidad al usuario.
- Optimizar hiperparámetros de modelos de *machine learning*: es fundamental refinar detalles relacionados a la configuración de los modelos empleados, a fin que la calidad de los resultados sean superiores.
- Obtener métricas y gráficos de cada modelo: estos les otorgan información extra a los usuarios respecto al contexto de sus predicciones.
- Comparar modelos y seleccionar el óptimo: es fundamental que el sistema le permita al usuario final realizar predicciones mediante el mejor modelo posible. Por ello, se comparan los distintos modelos entrenados y optimizados, a fin de encontrar al mejor de ellos.
- Seguimiento de resultados: al entrenar y comparar distintos modelos, es necesario hacer un seguimiento y una persistencia de ellos, como así también de sus métricas y gráficos. Esto facilita la consulta de esta información en distintas etapas, como así también su disposición para las consultas de los usuarios.
- Automatizar etapas: es de suma importancia que las etapas de análisis, optimización, entrenamiento y seguimiento de modelos sean automatizadas. Esto agiliza el ciclo de vida de la aplicación, permitiendo que las mejoras aplicadas al sistema sean publicadas de forma rápida y sencilla para el consumo de los usuarios.

- Comercialización y distribución: el trabajo se limita a la creación y despliegue local del sistema descrito, más no a su comercialización y/o distribución.

- Crear un servicio web: mediante una API web, un usuario puede realizar predicciones de quiebra al proveer los datos de una empresa en particular. También puede consultar métricas y gráficas de los modelos involucrados, incluyendo al mejor de ellos.

Por otra parte, dentro de las actividades que quedaron excluidas del alcance, se pueden mencionar:

- Despliegue online: el trabajo realizado se expone como un servicio web que se puede ejecutar de manera local. Es decir, no fue desplegado en plataformas de *cloud computing*, tales como Azure [11], AWS [12], Google Cloud [13], entre otras.
- Creación de interfaz web: el trabajo abarca desde la definición de un dataset, hasta la publicación de un servicio web que permite realizar predicciones de quiebra de una empresa. No se desarrolló un sitio web para consumir este servicio. No obstante, el servicio podrá ser utilizado mediante otras herramientas existentes, tales como cURL [14].
- Comercialización y distribución: el trabajo se limita a la creación y despliegue local del sistema descrito, más no a su comercialización y/o distribución.

de distintos algoritmos de *machine learning* con el fin de obtener un modelo. Estos modelos posteriormente nos permiten realizar predicciones o clasificaciones a partir de datos particulares de entrada.

En este trabajo, se implementan los siguientes modelos de *machine learning*:

- Regresión logística o *logistic regression* [9]: permite obtener la probabilidad de pertenencia a una de las clases de estudio. A partir de dicha probabilidad se determina a qué clase pertenece una muestra en particular.
- SVM o *support vector machine* [8]: se caracteriza por buscar un hiperplano que separe las clases de estudio con el margen más amplio posible.
- XGBoost [10]: consiste en un modelo de ensambles basado en árboles de decisión. Estos árboles son entrenados de manera secuencial, especializándose en corregir los errores del árbol anterior. Esto permite que sea un modelo robusto al evitar el sobreajuste.

2.3. Optimización de hiperparámetros

Los modelos de *machine learning* se caracterizan por tener hiperparámetros: variables de configuración que se definen antes de comenzar el entrenamiento. Estas se diferencian de un parámetro ya que controlan como se comporta el algoritmo.

A partir de esto, surge la necesidad de optimizar estos hiperparámetros con el fin de encontrar un equilibrio óptimo entre sesgo y varianza, lo cual a su vez permite evitar el sobreajuste (*overfitting*) o subajuste (*underfitting*) del modelo.

En este trabajo se utiliza el *framework* optuna [27]: una biblioteca de código abierto basada en python. Esta utiliza una optimización bayesiana para, en lugar de probar valores al azar, aprender de intentos anteriores y enfocarse en las combinaciones de hiperparámetros más prometedoras, encontrando así las más óptimas.

2.4. Herramientas - Tracking server

Al trabajar con distintos modelos de *machine learning* resulta crucial hacer un seguimiento de los mismos, enfocándose en los datos o datasets de entrada utilizados, los hiperparámetros configurados, las métricas y gráficos obtenidas luego del entrenamiento, entre otras cosas.

En este trabajo se utiliza MLFlow [28], una herramienta de código abierto que nos permite hacer este seguimiento y registro de configuraciones, a fin de utilizar tanto estos valores como los modelos en otras etapas del trabajo.

2.5. Herramientas para automatización

Este trabajo consta de distintas etapas, tales como el preprocesamiento de dataset, entrenamiento de modelos, optimización de hiperparámetros, obtención de métricas, entre otras.

El trabajo realizada en ellas se automatiza mediante la herramienta de código abierto Airflow [29], la cual nos permite programar, automatizar y monitorear los flujos de trabajo o *workflows* mencionados.

de distintos algoritmos de *machine learning* con el fin de obtener un modelo. Estos modelos posteriormente nos permiten realizar predicciones o clasificaciones a partir de datos particulares de entrada.

En este trabajo, se implementan los siguientes modelos de *machine learning*:

- Regresión logística o *logistic regression* [9]: permite obtener la probabilidad de pertenencia a una de las clases de estudio. A partir de dicha probabilidad se determina a qué clase pertenece una muestra en particular.
- SVM o *support vector machine* [8]: se caracteriza por buscar un hiperplano que separe las clases de estudio con el margen más amplio posible.
- XGBoost [10]: consiste en un modelo de ensambles basado en árboles de decisión. Estos árboles son entrenados de manera secuencial, especializándose en corregir los errores del árbol anterior. Esto permite que sea un modelo robusto al evitar el sobreajuste.

2.3. Optimización de hiperparámetros

Los modelos de *machine learning* se caracterizan por tener hiperparámetros: variables de configuración que se definen antes de comenzar el entrenamiento. Estas se diferencian de un parámetro ya que controlan como se comporta el algoritmo.

A partir de esto, surge la necesidad de optimizar estos hiperparámetros con el fin de encontrar un equilibrio óptimo entre sesgo y varianza, lo cual a su vez permite evitar el sobreajuste (*overfitting*) o subajuste (*underfitting*) del modelo.

En este trabajo se utiliza el *framework* optuna [27]: una biblioteca de código abierto basada en python. Esta utiliza una optimización bayesiana para, en lugar de probar valores al azar, aprender de intentos anteriores y enfocarse en las combinaciones de hiperparámetros más prometedoras, encontrando así las más óptimas.

2.4. Herramientas - Tracking server

Al trabajar con distintos modelos de *machine learning* resulta crucial hacer un seguimiento de los mismos, enfocándose en los datos o datasets de entrada utilizados, los hiperparámetros configurados, las métricas y gráficos obtenidas luego del entrenamiento, entre otras cosas.

En este trabajo se utiliza MLFlow [28], una herramienta de código abierto que nos permite hacer este seguimiento y registro de configuraciones, a fin de utilizar tanto estos valores como los modelos en otras etapas del trabajo.

2.5. Herramientas para automatización

Este trabajo consta de distintas etapas, tales como el preprocesamiento de dataset, entrenamiento de modelos, optimización de hiperparámetros, obtención de métricas, entre otras.

El trabajo realizada en ellas se automatiza mediante la herramienta de código abierto Airflow [29], la cual nos permite programar, automatizar y monitorear los flujos de trabajo o *workflows* mencionados.

Estos *workflows* se organizan mediante DAGs [30], o grafo acíclico dirigido por sus siglas en inglés, los cuales siguen un orden lógico (secuencial o en paralelo) sin bucles para lograr un objetivo. De esta forma, se pueden orquestar tareas y escalar procesos de manera automática.

2.6. Desarrollo de API y herramientas para su consumo

En este trabajo se presenta una herramienta web que permite realizar predicciones sobre la quiebra de una empresa. Esta consiste en un API Rest, una interfaz de programación de aplicaciones cuya arquitectura, basada en REST [31], permite la comunicación e intercambio de datos mediante el protocolo HTTP. Esto permite que el servicio web sea escalable, ya que las distintas peticiones de clientes se pueden distribuir entre distintas instancias de un mismo servicio; y simple, ya que tiene métodos HTTP o *endpoints* para operaciones como predicción, recuperación de datos, etc.

Para desarrollarlo, se usa el framework FastAPI [32], el cual permite programar las API utilizando código python, brindando simplicidades tales como la documentación automática, el soporte de métodos asincrónicos, validación automática de datos de entrada, entre otras.

Para validar el correcto funcionamiento de esta API se utilizan herramientas como curl [14] y postman [33], las cuales permiten realizar peticiones web a los distintos *endpoints* disponibles, tanto de manera manual como automática.

2.7. Uso de contenedores

Las distintas herramientas mencionadas se pueden utilizar de diferentes maneras. Una de estas es mediante el uso de contenedores.

Un contenedor o *container* es una unidad de software que empaqueta a una aplicación y a todas sus dependencias a fin de que se ejecute de forma rápida en cualquier entorno. Es decir, permite que un software sea portable, ya que se puede utilizar tanto de manera local como en la nube; aislado, ya que varias aplicaciones se pueden ejecutar en el mismo entorno sin afectarse entre sí; y fácil de desplegar.

El uso de contenedores en este trabajo se usan contenedores mediante la herramienta Docker [34].

Estos *workflows* se organizan mediante DAGs [30], o grafo acíclico dirigido por sus siglas en inglés, los cuales siguen un orden lógico (secuencial o en paralelo) sin bucles para lograr un objetivo. De esta forma, se pueden orquestar tareas y escalar procesos de manera automática.

2.6. Desarrollo de API y herramientas para su consumo

En este trabajo se presenta una herramienta web que permite realizar predicciones sobre la quiebra de una empresa. Esta consiste en un API Rest, una interfaz de programación de aplicaciones cuya arquitectura, basada en REST [31], permite la comunicación e intercambio de datos mediante el protocolo HTTP. Esto permite que el servicio web sea escalable, ya que las distintas peticiones de clientes se pueden distribuir entre distintas instancias de un mismo servicio; y simple, ya que tiene métodos HTTP o *endpoints* para operaciones como predicción, recuperación de datos, etc.

Para desarrollarlo, se usa el framework FastAPI [32], el cual permite programar las API utilizando código python, brindando simplicidades tales como la documentación automática, el soporte de métodos asincrónicos, validación automática de datos de entrada, entre otras.

Para validar el correcto funcionamiento de esta API se utilizan herramientas como curl [14] y postman [33], las que permiten realizar peticiones web a los distintos *endpoints* disponibles, tanto de manera manual como automática.

2.7. Uso de contenedores

Las distintas herramientas mencionadas se pueden utilizar de diferentes maneras. Una de estas es mediante el uso de contenedores.

Un contenedor o *container* es una unidad de software que empaqueta a una aplicación y a todas sus dependencias a fin de que se ejecute de forma rápida en cualquier entorno. Es decir, permite que un software sea portable, ya que se puede utilizar tanto de manera local como en la nube; aislado, ya que las aplicaciones no se afectan entre sí; y fácil de desplegar.

En este trabajo se usa la herramienta Docker [34] para trabajar con contenedores.

TABLA 4.5. Evaluación del dataset ruso.

Métrica	Dataset de Rusia	Dataset de Taiwán
recall	1	0,7727
precision	0,2993	0,2227
f1-score	0,4606	0,3457
f2-score	0,6810	0,5172
AUPRC (average precision)	0,6422	0,3259
AUC-ROC	0,8773	0,9210

En este caso se obtuvieron mejores métricas que con el dataset de Polonia. Algunas de estas son incluso mejores que la del dataset original. La métrica AUC-ROC, con valor de 0,8773, es mucho mejor que el caso del dataset polaco (0,5096, que indica un comportamiento azaroso), pero menor a la del dataset de Taiwán (0,9210). El *recall* es 1, pero a diferencia del dataset polaco, la métrica de *precision* es de 0,2993. Esto indica que el modelo genera muchos falsos positivos. Por ejemplo, de 10 casos clasificados como quiebra, solo 3 serán correctos. Por su parte, la métrica AUPRC (0,6422) es mejor que las obtenidas en el dataset de Polonia (0,0429) y de Taiwán (0,3259). Esto indica que el modelo mantiene una buena relación entre *precision* y *recall*.

Se puede decir que el modelo entrenado con el dataset de Taiwán puede detectar quiebras asociadas al mercado ruso, pero es sensible a clasificar erróneamente a empresas sanas. Esta imprecisión puede deberse al formato del dataset ruso, que solamente tiene 11 columnas equivalentes con el dataset de Taiwán. De manera similar al caso Polonia, pueden haber también diferentes legislaciones y/o definiciones que inciden en la definición de una quiebra.

4.6.3. Dataset de Estados Unidos

Se utiliza el dataset de *Bankruptcy prediction dataset for american companies in the stock market* 4.6.3, que contiene información financiera de empresas que cotizan en bolsas estadounidenses (NYSE y NASDAQ). Esta información cubre los años entre 1998 y 2018, y se divide en 78682 y 21 columnas. Solo 13 de estas 21 **columnas** tienen un equivalente en el dataset de Taiwán:

- Bankrupt?: Se obtiene a partir de la columna *status_label* del dataset de Estados Unidos. Es la variable objetivo. Se caracteriza por estar **desbalanceada** (5220 presentan quiebra, mientras que 73462 no).
- Net Income to Total Assets: división entre las columnas X6 y X10 del dataset de Estados Unidos. Representa la rentabilidad sobre activos (ROA).
- Debt ratio%: división entre las columnas X17 y X10 del dataset de Estados Unidos. Representa la proporción de deuda.
- Current Ratio: división entre las columnas X1 y X14 del dataset de Estados Unidos. Es la capacidad de la empresa para pagar sus deudas a corto plazo con sus activos corrientes.

TABLA 4.5. Evaluación del dataset ruso.

Métrica	Dataset de Rusia	Dataset de Taiwán
recall	1	0,7727
precision	0,2993	0,2227
f1-score	0,4606	0,3457
f2-score	0,6810	0,5172
AUPRC (average precision)	0,6422	0,3259
AUC-ROC	0,8773	0,9210

En este caso se obtuvieron mejores métricas que con el dataset de Polonia. Algunas de estas son incluso mejores que la del dataset original. La métrica AUC-ROC, con valor de 0,8773, es mucho mejor que el caso del dataset polaco (0,5096, que indica un comportamiento azaroso), pero menor a la del dataset de Taiwán (0,9210). El *recall* es 1, pero a diferencia del dataset polaco, la métrica de *precision* es de 0,2993. Esto indica que el modelo genera muchos falsos positivos. Por ejemplo, de 10 casos clasificados como quiebra, solo 3 serán correctos. Por su parte, la métrica AUPRC (0,6422) es mejor que las obtenidas en el dataset de Polonia (0,0429) y de Taiwán (0,3259). Esto indica que el modelo mantiene una buena relación entre *precision* y *recall*.

Se puede decir que el modelo entrenado con el dataset de Taiwán puede detectar quiebras asociadas al mercado ruso, pero es sensible a clasificar erróneamente a empresas sanas. Esta imprecisión puede deberse al formato del dataset ruso, que solamente tiene 11 columnas equivalentes con el dataset de Taiwán. De manera similar al caso Polonia, pueden haber también diferentes legislaciones y/o definiciones que inciden en la definición de una quiebra.

4.6.3. Dataset de Estados Unidos

Se utiliza el dataset de *Bankruptcy prediction dataset for american companies in the stock market* [67], que contiene información financiera de empresas que cotizan en bolsas estadounidenses (NYSE y NASDAQ). Esta información cubre los años entre 1998 y 2018, y se divide en 78682 y 21 columnas. Solo 13 de estas 21 **columnas** tienen un equivalente en el dataset de Taiwán:

- Bankrupt?: se obtiene a partir de la columna *status_label* del dataset de Estados Unidos, y se trata de la variable objetivo. Se caracteriza por estar **desbalanceada** (5220 presentan quiebra, mientras que 73462 no).
- Net Income to Total Assets: división entre las columnas X6 y X10 del dataset de Estados Unidos. Representa la rentabilidad sobre activos (ROA).
- Debt ratio%: división entre las columnas X17 y X10 del dataset de Estados Unidos. Representa la proporción de deuda.
- Current Ratio: división entre las columnas X1 y X14 del dataset de Estados Unidos. Es la capacidad de la empresa para pagar sus deudas a corto plazo con sus activos corrientes.

- Retained Earnings to Total Assets: división entre las columnas X15 y X10 del dataset de Estados Unidos. Mide el apalancamiento histórico y la capacidad de reinversión acumulada.
- Operating Gross Margin: división entre las columnas X13 y X9 del dataset de Estados Unidos. Representa el margen bruto operativo.
- Net worth/Assets: **Patrimonio** neto sobre activos. Se calcula mediante la fórmula $(X10 - X17) / X10$.
- Quick Ratio: **Se** calcula mediante la fórmula $(X1 - X5) / X14$. Es la capacidad de pago inmediato.
- Liability to Equity: **Consiste** en la relación **Deuda/Capital**. Se calcula mediante la fórmula $X17 / (X10 - X17)$.
- Net Income to Stockholder's Equity: **Rentabilidad** sobre **Capital**. Se calcula mediante la fórmula $X6 / (X10 - X17)$.
- Current Liability to Assets: **Pasivo** circulante sobre activos. Se obtiene al dividir las columnas X14 y X10 del dataset de Estados Unidos.
- ROA (C) before interest and ...: **Rentabilidad** operativa. Se obtiene al dividir las columnas X4 y X10.
- Working Capital to Total Assets: **Capital** de trabajo sobre activos. Se calcula mediante la fórmula $(X1 - X14) / X10$.

La evaluación se realiza con el mejor modelo, XGBoost con *pipelines*. Los resultados se muestran en la tabla 4.6.

TABLA 4.6. Evaluación del dataset estadounidense.

Métrica	Dataset de Rusia	Dataset de Taiwán
recall	0,9941	0,7727
precision	0,0667	0,2227
f1-score	0,1250	0,3457
f2-score	0,2628	0,5172
AUPRC (average precision)	0,0663	0,3259
AUC-ROC	0,4999	0,9210

Similar al caso del dataset polaco 4.6.1, se **obtienen** métricas muy bajas. Se **tiene** un AUC-ROC de 0,4999, que indica un **comportamiento** similar a un modelo aleatorio. Si bien el *recall* es un valor muy alto (0,9941), si se analiza la *precision* (0,0667), se concluye que el modelo clasifica a la mayoría de los casos como **quiebra**, independientemente de que lo sean o no.

Esta baja performance puede deberse a:

- Diferencia de columnas entre datasets: el dataset de Taiwán tiene 95 columnas, pero el de Estados Unidos solo tiene 13 columnas equivalentes.
- Diferentes formas de medir una quiebra: ambos países pueden tener diferentes normas contables y/o legislaciones de quiebra.

- Retained Earnings to Total Assets: división entre las columnas X15 y X10 del dataset de Estados Unidos. Mide el apalancamiento histórico y la capacidad de reinversión acumulada.
- Operating Gross Margin: división entre las columnas X13 y X9 del dataset de Estados Unidos. Representa el margen bruto operativo.
- Net worth/Assets: **patrimonio** neto sobre activos. Se calcula mediante la fórmula $(X10 - X17) / X10$.
- Quick Ratio: **se** calcula mediante la fórmula $(X1 - X5) / X14$. Es la capacidad de pago inmediato.
- Liability to Equity: **consiste** en la relación **deuda/capital**. Se calcula mediante la fórmula $X17 / (X10 - X17)$.
- Net Income to Stockholder's Equity: **Se calcula mediante la fórmula** $X6 / (X10 - X17)$. Representa la rentabilidad sobre capital.
- Current Liability to Assets: **pasivo** circulante sobre activos. Se obtiene al dividir las columnas X14 y X10 del dataset de Estados Unidos.
- ROA (C) before interest and ...: **rentabilidad** operativa. Se obtiene al dividir las columnas X4 y X10.
- Working Capital to Total Assets: **capital** de trabajo sobre activos. Se calcula mediante la fórmula $(X1 - X14) / X10$.

La evaluación se realiza con el mejor modelo, XGBoost con *pipelines*. Los resultados se muestran en la tabla 4.6.

TABLA 4.6. Evaluación del dataset estadounidense.

Métrica	Dataset de Rusia	Dataset de Taiwán
recall	0,9941	0,7727
precision	0,0667	0,2227
f1-score	0,1250	0,3457
f2-score	0,2628	0,5172
AUPRC (average precision)	0,0663	0,3259
AUC-ROC	0,4999	0,9210

Similar al caso del dataset polaco **que se detalla en la sección 4.6.1**, se **obtuvieron** métricas muy bajas. Se **tiene** un AUC-ROC de 0,4999, que indica un **comportamiento** similar a un modelo aleatorio. Si bien el *recall* es un valor muy alto (0,9941), si se analiza la *precision* (0,0667), se concluye que el modelo clasifica a la mayoría de los casos como **quiebra**, independientemente de que lo sean o no.

Esta baja performance puede deberse a:

- Diferencia de columnas entre datasets: el dataset de Taiwán tiene 95 columnas, pero el de Estados Unidos solo tiene 13 columnas equivalentes.
- Diferentes formas de medir una quiebra: ambos países pueden tener diferentes normas contables y/o legislaciones de quiebra.

- [62] *pydantic*. <https://pydantic.dev/docs/>.
- [63] *pydantic - Base model*. https://pydantic.dev/docs/validation/latest/api/pydantic/base_model/.
- [64] *pydantic - Field*. <https://pydantic.dev/docs/validation/latest/concepts/fields/>.
- [65] Sebastian Tomczak. *Polish Companies Bankruptcy*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5F600>. 2016.
- [66] Institute for the Rule of Law at European University at St. Petersburg. *RFSD (Revision ee9414b)*. 2025. DOI: [10.57967/hf/4574](https://doi.org/10.57967/hf/4574). URL: <https://huggingface.co/datasets/irlspbru/RFSD>.

- [62] *pydantic*. <https://pydantic.dev/docs/>.
- [63] *pydantic - Base model*. https://pydantic.dev/docs/validation/latest/api/pydantic/base_model/.
- [64] *pydantic - Field*. <https://pydantic.dev/docs/validation/latest/concepts/fields/>.
- [65] Sebastian Tomczak. *Polish Companies Bankruptcy*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5F600>. 2016.
- [66] Institute for the Rule of Law at European University at St. Petersburg. *RFSD (Revision ee9414b)*. 2025. DOI: [10.57967/hf/4574](https://doi.org/10.57967/hf/4574). URL: <https://huggingface.co/datasets/irlspbru/RFSD>.
- [67] Intelligent SOWIDE Social Web y Distributed systems Engineering LAB. *Bankruptcy prediction dataset for american companies in the stock market*. 2022. URL: https://github.com/sowide/bankruptcy_dataset.