.UBAfiuba
FACULTAD DE INGENIERÍA

Predicción de quiebra de empresas mediante técnicas de machine learning

Gaspar Acevedo Zain

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Ariadna Garmendia (FIUBA)

Jurados:

Jurado 1 (pertenencia)
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

Buenos Aires, marzo de 2026

Resumen

En esta memoria se describe el análisis, diseño y puesta en marcha de un sistema que permite detectar si una empresa puede entrar en quiebra. Este sistema será ofrecido como un servicio con el fin de proporcionar información estratégica a potenciales clientes. De esta manera clientes como analistas de riegos, ejecutivos de créditos, entre otros, podrán tomar decisiones críticas en sus negocios.

La resolución de este trabajo fue posible gracias a la implementación de conocimientos aprendidos durante la especialización, tales como técnicas de análisis de datos, modelos de machine learning, automatización de procesos en entornos de mlops y puesta en producción de modelos mediante APIs.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen I

1. Introducción general 1
1.1. Predicción de quiebra de empresas 1
1.2. Estado del arte 1
1.3. Motivación 2
1.4. Objetivos y alcance 2

2. Introducción específica 5
2.1. Estilo y convenciones 5
2.1.1. Uso de mayúscula inicial para los título de secciones 5
2.1.2. Este es el título de una subsección 5
2.1.3. Figuras 6
2.1.4. Tablas 7
2.1.5. Ecuaciones 8

3. Diseño e implementación 9
3.1. Análisis del software 9

4. Ensayos y resultados 11
4.1. Pruebas funcionales del hardware 11

5. Conclusiones 13
5.1. Conclusiones generales 13
5.2. Próximos pasos 13

Bibliografía 15

Índice de figuras

1.1. Diagrama en bloques. 2

2.1. Ilustración del cuadrado azul que se eligió para el diseño del logo. 6
2.2. Imagen tomada de la página oficial del procesador[1]. 7
2.3. ¿Por qué de pronto aparece esta figura? 7
2.4. Tres gráficos simples. 7

Índice de tablas

2.1. caption corto 8

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se explica la importancia de la predicción de quiebra de empresas. Luego, se detalla el estado del arte actual respecto a esta temática. Se explican también las motivaciones detrás de este trabajo. Finalmente, se describen los objetivos y alcance del trabajo.

1.1. Predicción de quiebra de empresas

Predecir si una empresa entra en quiebra es información de gran valor para distintos actores del mercado financiero. Acceder a esta información en tiempo y forma le permitirá a bancos, compañías aseguradoras, fondos de inversión o consultoras especializadas en riesgo crediticio tomar mejores decisiones en sus respectivas labores.

El presente trabajo es un emprendimiento personal orientado a la resolución de la problemática presentada. Para llevarlo a cabo, se utiliza el dataset de *Taiwanese Bankruptcy Prediction*[1], el cual contiene información financiera de empresas del mercado de Taiwán entre 1999 y 2009, y fue publicado por el *Taiwan Economic Journal*[1]. Esta información será utilizada en el entorno de trabajo que se puede apreciar en la figura 1.1. En este, se refina la información, se entrenan distintos modelos de machine learning, y se comparan dichos modelos a fin de elegir al mejor de ellos. Los resultados obtenidos se publican mediante un servicio web, para que los distintos interesados pueden consultarlos y utilizarlos según sus necesidades.

1.2. Estado del arte

Existen diversos estudios basados en el dataset de *Taiwanese Bankruptcy Prediction*[1]. En algunos de ellos, como en *Comprehensive Evaluation of Bankruptcy Prediction in Taiwanese Firms Using Multiple Machine Learning Models*, se exploran modelos de *machine learning* tales como SVM (*Support Vector Machine*)[2] y *Random Forest*[3]. En otros, se analiza cómo ciertas técnicas afectan a las predicciones finales. Por ejemplo, en *Undersampling bankruptcy prediction: Taiwan bankruptcy data*[4] se estudian los resultados de aplicar técnicas de preprocesamiento de datos mediante *undersampling*.

[1] https://www.tejwin.com/en/

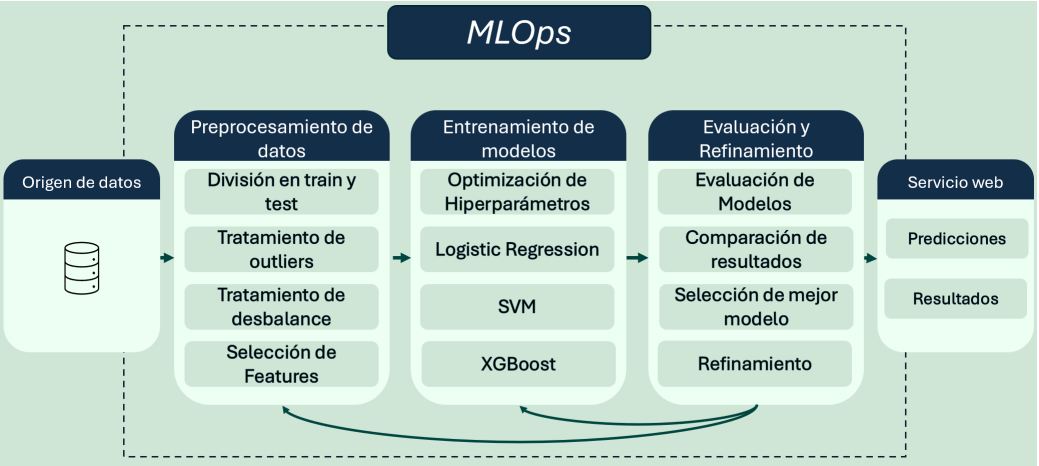

FIGURA 1.1. Diagrama en bloques.

Independientemente de los modelos y de las técnicas de preprocesamiento utilizadas, los estudios actuales se limitan a presentar resultados numéricos y conclusiones sobre las herramientas utilizadas, pero ninguno permite utilizar los modelos obtenidos para realizar predicciones reales.

1.3. Motivación

Este trabajo busca solucionar las siguientes problemáticas:

- Permitir a actores del mercado financiero predecir si una empresa entra en quiebra.
- Resolver las limitaciones de trabajos actuales, en donde solo se presentan resultados numéricos y conclusiones.

Por ello, se diseña y desarrolla un sistema que implementa técnicas y modelos de *machine learning*. Estos modelos, son entrenados, refinados y comparados para encontrar al que mejor prediga si una empresa entra en quiebra. Una vez seleccionado el mejor de ellos, se lo expone mediante un servicio web, a fin de que distintos interesados puedan utilizarlo según sus necesidades.

1.4. Objetivos y alcance

Este trabajo busca crear y exponer, mediante servicio web, un sistema que prediga si una empresa entra en quiebra. Para ello, se define un entorno de trabajo que se caracteriza por ser iterativo, reproducible y escalable, en donde se usa un dataset de origen público[1]. Sobre este dataset se aplicarán técnicas de preprocesamiento de datos para mejorarlo. Luego, se entrenarán modelos de *machine learning*, que permitan realizar las predicciones deseadas. Estos modelos serán evaluados y comparados entre sí, a fin de encontrar al "mejor"de ellos. El mejor modelo y los resultados obtenidos serán expuestos mediante un servicio web, para que cualquier interesado pueda hacer uso de ellos. Sobre estos resultados se vuelven a aplicar las técnicas ya mencionadas, para poder refinarlos y reevaluarlos.

A partir de esto, se define el siguiente alcance:

- Análisis exploratorio de datos: se estudia al dataset en cuestión, para poder conocer mejor sus características, distribuciones, y potenciales errores a corregir.
- Preprocesamiento de datos: se aplican técnicas para eliminar duplicados, corrección de datos faltantes, corrección de *outliers*, balanceo de datos, entre otras.
- Implementación de modelos de *machine learning*: se implementan modelos como SVM[2], *logistic regression*[5] y *XGBoost*[6].
- Evaluación de modelos: se obtienen métricas y gráficos asociados a cada modelo, para poder compararlos entre sí.
- Automatización: se automatizan los pasos anteriores, a fin de preparar los resultados para el servicio web.
- Trackeo de resultados: se utiliza el servicio *MLFlow*[7] para hacer seguimiento de los modelos entrenados y sus métricas.
- Creación de un servicio web: se crea una *API* web la cual expone al mejor modelo entrenado, como así también las métricas y gráficos de todos los modelos.

De la misma manera, se definen las actividades que quedan excluídas de este trabajo:

- Despliegue del servicio en plataformas de *cloud computing*, tales como Azure[8], AWS[9], Google Cloud[10], entre otras.
- Creación de interfaz web: el trabajo se limita hasta la creación de una *API* web, la cual se podrá utilizar mediante herramientas existentes, tales como *cURL*[11] y otras similares.
- Comercialización y distribución: el trabajo se limita a la creación del sistema descrito, más no a su comercialización y/o distribución.

Capítulo 2

Introducción específica

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

2.1. Estilo y convenciones

2.1.1. Uso de mayúscula inicial para los título de secciones

Si en el texto se hace alusión a diferentes partes del trabajo referirse a ellas como capítulo, sección o subsección según corresponda. Por ejemplo: "En el capítulo 1 se explica tal cosa", o "En la sección 2.1 se presenta lo que sea", o "En la subsección 2.1.2 se discute otra cosa".

Cuando se quiere poner una lista tabulada, se hace así:

- Este es el primer elemento de la lista.
- Este es el segundo elemento de la lista.

Notar el uso de las mayúsculas y el punto al final de cada elemento.

Si se desea poner una lista numerada el formato es este:

1. Este es el primer elemento de la lista.
2. Este es el segundo elemento de la lista.

Notar el uso de las mayúsculas y el punto al final de cada elemento.

2.1.2. Este es el título de una subsección

Se recomienda no utilizar **texto en negritas** en ningún párrafo, ni tampoco texto subrayado. En cambio sí se debe utilizar *texto en itálicas* para palabras en un idioma extranjero, al menos la primera vez que aparecen en el texto. En el caso de palabras que estamos inventando se deben utilizar "comillas", así como también para citas textuales. Por ejemplo, un *digital filter* es una especie de "selector" que permite separar ciertos componentes armónicos en particular.

La escritura debe ser impersonal. Por ejemplo, no utilizar "el diseño del firmware lo hice de acuerdo con tal principio", sino "el firmware fue diseñado utilizando tal principio".

El trabajo es algo que al momento de escribir la memoria se supone que ya está concluido, entonces todo lo que se refiera a hacer el trabajo se narra en tiempo pasado, porque es algo que ya ocurrió. Por ejemplo, "se diseñó el firmware empleando la técnica de test driven development".

En cambio, la memoria es algo que está vivo cada vez que el lector la lee. Por eso transcurre siempre en tiempo presente, como por ejemplo:

"En el presente capítulo se da una visión global sobre las distintas pruebas realizadas y los resultados obtenidos. Se explica el modo en que fueron llevados a cabo los test unitarios y las pruebas del sistema".

Se recomienda no utilizar una sección de glosario sino colocar la descripción de las abreviaturas como parte del mismo cuerpo del texto. Por ejemplo, RTOS (*Real Time Operating System*, Sistema Operativo de Tiempo Real) o en caso de considerarlo apropiado mediante notas a pie de página.

Si se desea indicar alguna página web utilizar el siguiente formato de referencias bibliográficas, dónde las referencias se detallan en la sección de bibliografía de la memoria, utilizado el formato establecido por IEEE en [12]. Por ejemplo, "el presente trabajo se basa en la plataforma EDU-CIAA-NXP [13], la cual...".

2.1.3. Figuras

Al insertar figuras en la memoria se deben considerar determinadas pautas. Para empezar, usar siempre tipografía claramente legible. Luego, tener claro que **es incorrecto** escribir por ejemplo esto: "El diseño elegido es un cuadrado, como se ve en la siguiente figura:"

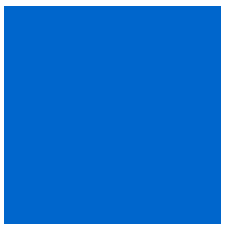

La forma correcta de utilizar una figura es con referencias cruzadas, por ejemplo: "Se eligió utilizar un cuadrado azul para el logo, como puede observarse en la figura 2.1".

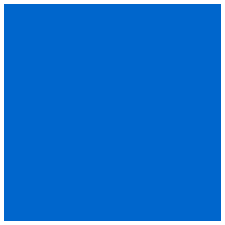

FIGURA 2.1. Ilustración del cuadrado azul que se eligió para el diseño del logo.

El texto de las figuras debe estar siempre en español, excepto que se decida reproducir una figura original tomada de alguna referencia. En ese caso la referencia de la cual se tomó la figura debe ser indicada en el epígrafe de la figura e incluida como una nota al pie, como se ilustra en la figura 2.2.

FIGURA 2.2. Imagen tomada de la página oficial del procesador[1].

La figura y el epígrafe deben conformar una unidad cuyo significado principal pueda ser comprendido por el lector sin necesidad de leer el cuerpo central de la memoria. Para eso es necesario que el epígrafe sea todo lo detallado que corresponda y si en la figura se utilizan abreviaturas entonces aclarar su significado en el epígrafe o en la misma figura.

FIGURA 2.3. ¿Por qué de pronto aparece esta figura?

Nunca colocar una figura en el documento antes de hacer la primera referencia a ella, como se ilustra con la figura 2.3, porque sino el lector no comprenderá por qué de pronto aparece la figura en el documento, lo que distraerá su atención.

Otra posibilidad es utilizar el entorno *subfigure* para incluir más de una figura, como se puede ver en la figura 2.4. Notar que se pueden referenciar también las figuras internas individualmente de esta manera: 2.4a, 2.4b y 2.4c.

(A) Un caption.

(B) Otro.

(C) Y otro más.

FIGURA 2.4. Tres gráficos simples.

El código para generar las imágenes se encuentra disponible para su reutilización en el archivo **`Chapter2.tex`**.

2.1.4. Tablas

Para las tablas utilizar el mismo formato que para las figuras, sólo que el epígrafe se debe colocar arriba de la tabla, como se ilustra en la tabla 2.1. Observar que sólo algunas filas van con líneas visibles y notar el uso de las negritas para los encabezados. La referencia se logra utilizando el comando `\ref{<label>}` donde label debe estar definida dentro del entorno de la tabla.

[1]Imagen tomada de https://goo.gl/images/i7C70w

```
\begin{table}[h]
 \centering
 \caption[caption corto]{caption largo más descriptivo}
 \begin{tabular}{l c c}
  \toprule
  \textbf{Especie}     & \textbf{Tamaño} & \textbf{Valor}\\
  \midrule
  Amphiprion Ocellaris & 10 cm           & \$ 6.000 \\
  Hepatus Blue Tang    & 15 cm           & \$ 7.000 \\
  Zebrasoma Xanthurus  & 12 cm           & \$ 6.800 \\
  \bottomrule
  \hline
 \end{tabular}
 \label{tab:peces}
\end{table}
```

TABLA 2.1. caption largo más descriptivo.

Especie	**Tamaño**	**Valor**
Amphiprion Ocellaris	10 cm	$ 6.000
Hepatus Blue Tang	15 cm	$ 7.000
Zebrasoma Xanthurus	12 cm	$ 6.800

En cada capítulo se debe reiniciar el número de conteo de las figuras y las tablas, por ejemplo, figura 2.1 o tabla 2.1, pero no se debe reiniciar el conteo en cada sección. Por suerte la plantilla se encarga de esto por nosotros.

2.1.5. Ecuaciones

Al insertar ecuaciones en la memoria dentro de un entorno *equation*, éstas se numeran en forma automática y se pueden referir al igual que como se hace con las figuras y tablas, por ejemplo ver la ecuación 2.1.

$$ds^2 = c^2 dt^2 \left(\frac{d\sigma^2}{1-k\sigma^2} + \sigma^2 \left[d\theta^2 + \sin^2\theta d\phi^2 \right] \right) \tag{2.1}$$

Para generar la ecuación 2.1 se utilizó el siguiente código:

```
\begin{equation}
 \label{eq:metric}
 ds^2 = c^2 dt^2 \left( \frac{d\sigma^2}{1-k\sigma^2} +
 \sigma^2\left[ d\theta^2 +
 \sin^2\theta d\phi^2 \right] \right)
\end{equation}
```

Capítulo 3

Diseño e implementación

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

3.1. Análisis del software

La idea de esta sección es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado.

Se puede agregar código o pseudocódigo dentro de un entorno lstlisting con el siguiente código:

```
\begin{lstlisting}[caption= "un epígrafe descriptivo"]
 las líneas de código irían aquí...
\end{lstlisting}
```

A modo de ejemplo, se muestra el fragmento de código 3.1:

```
#define MAX_SENSOR_NUMBER 3
#define MAX_ALARM_NUMBER  6
#define MAX_ACTUATOR_NUMBER 6

uint32_t sensorValue[MAX_SENSOR_NUMBER];
FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
state_t alarmState[MAX_ALARM_NUMBER];           //ON or OFF
state_t actuatorState[MAX_ACTUATOR_NUMBER];     //ON or OFF

void vControl() {

  initGlobalVariables();

  period = 500 ms;

  while(1) {

    ticks = xTaskGetTickCount();

    updateSensors();

    updateAlarms();

    controlActuators();

    vTaskDelayUntil(&ticks, period);
  }
```

```
28 }
```

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se puedo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

[1] Taiwan Economic Journal. *Taiwanese Bankruptcy Prediction*. UCI Machine Learning Repository. DOI: https://doi.org/10.24432/C5004D. 2020.

[2] Theodoros Evgeniou y Massimiliano Pontil. «Support Vector Machines: Theory and Applications». En: *Support Vector Machines: Theory and Applications*. Vol. 2049. Sep. de 2001, págs. 249-257. ISBN: 978-3-540-42490-1. DOI: 10.1007/3-540-44673-7_12.

[3] Gilles Louppe. *Understanding Random Forests: From Theory to Practice*. 2015. arXiv: 1407.7502 [stat.ML]. URL: https://arxiv.org/abs/1407.7502.

[4] Haoming Wang y Xiangdong Liu. «Undersampling bankruptcy prediction: Taiwan bankruptcy data». En: *PLOS ONE* 16.7 (jul. de 2021), págs. 1-17. DOI: 10.1371/journal.pone.0254030. URL: https://doi.org/10.1371/journal.pone.0254030.

[5] Moo K. Chung. *Introduction to logistic regression*. 2020. arXiv: 2008.13567 [stat.ME]. URL: https://arxiv.org/abs/2008.13567.

[6] Tianqi Chen y Carlos Guestrin. «XGBoost: A Scalable Tree Boosting System». En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. KDD '16. ACM, ago. de 2016, 785–794. DOI: 10.1145/2939672.2939785. URL: http://dx.doi.org/10.1145/2939672.2939785.

[7] *MLFlow*. https://mlflow.org/.

[8] *Azure*. https://azure.microsoft.com/en-us.

[9] *AWS*. https://aws.amazon.com/.

[10] *Google Cloud*. https://cloud.google.com/.

[11] *cURL*. https://curl.se/.

[12] IEEE. *IEEE Citation Reference*. 1.ª ed. IEEE Publications, 2016. URL: http://www.ieee.org/documents/ieeecitationref.pdf (visitado 26-09-2016).

[13] Proyecto CIAA. *Computadora Industrial Abierta Argentina*. Visitado el 2016-06-25. 2014. URL: http://proyecto-ciaa.com.ar/devwiki/doku.php?id=start.